Análisis Exploratorio de Datos en R

Felipe José Bravo Márquez

13 de noviembre de 2013

Análisis Exploratorio de Datos

- El análisis exploratorio de datos o (EDA) engloba un conjunto de técnicas para poder comprender de manera rápida la naturaleza de una colección de datos o dataset.
- Fue creado por el estadístico John Tukey.
- Se basa principalmente en dos criterios: Las estadísticas de resumen y la visualización de datos
- En esta clase se verán ambos tipos de técnicas, además de su aplicación en R para datasets conocidos.

El dataset Iris

- Trabajaremos con un dataset muy conocido en análisis de datos llamado Iris.
- El dataset se compone de 150 observaciones de flores de la planta iris.
- Existen tres tipos de clases de flores iris: virginica, setosa y versicolor.
- Hay 50 observaciones de cada una.
- Las variables o atributos que se miden de cada flor son:
 - El tipo de flor como variable categórica.
 - El largo y el ancho del pétalo en cm como variables numéricas.
 - 3 El largo y el ancho del sépalo en cm como variables numéricas.



El dataset Iris







Figura: Virginica - Setosa - Versicolor

• El dataset se encuentra disponible en R:

 Para poder acceder a las variables directamente usamos el comando attach (iris).

Estadísticas de Resumen

- Las estadísticas de resumen son valores que explican propiedades de los datos.
- Algunas de estas propiedades incluyen: frecuencias, medidas de tendencia central y dispersión.
- Ejemplos:
 - Tendencia central: media, mediana, moda.
 - Dispersión: miden la variabilidad de los datos, como la desviación estándar, el rango, etc..
- La mayor parte de las estadísticas de resumen se pueden calcular haciendo una sola pasada por los datos.

Frecuencia y Moda

- La frecuencia de un valor de atributo es el porcentaje de veces que éste es observado.
- En R podemos contar las frecuencias de aparición de cada valor distinto de un vector usando el comando table:

Ejercicio: Calcular las frecuencias porcentuales del vector anterior.

```
> table(vec)/length(vec) # Frecuencia porcentual
vec
    0   1   2   3
0.2   0.3   0.1   0.4
```

Frecuencia y Moda (2)

- La moda de un atributo es el valor más frecuente observado.
- No existe la función moda directamente en R, pero es fácil de calcular usando table y max:

```
my_mode<-function(var){
  frec.var<-table(var)
  valor<-which(frec.var==max(frec.var))  # Elementos con el valor
  names(valor)
}
> my_mode(vec)
[1] "3"
> my_mode(iris$Sepal.Length)
[1] "5"
```

 Generalmente usamos la frecuencia y la moda para estudiar variables categóricas.

Medidas de Tendencia Central

- Estas medidas tratan de resumir los valores observados en único valor asociado al valor localizado en el centro.
- La media es la medida más común de tendencia central para una variable numérica.
- Si tenemos m observaciones se calcula como la media aritmética o promedio.

$$\operatorname{mean}(x) = \overline{x} = \frac{1}{m} \sum_{i=1}^{m} x_i$$

- El mayor problema de la media es que es una medida muy sensible a outliers o valores atípicos.
- Ejemplo: Tomamos un vector aleatorio de media 20 y luego le agregamos un elemento aleatorio que proviene de una distribución de media mucho mayor.
 Vemos que la media es fuertemente afectada por el ruido:

```
> vec<-rnorm(10,20,10)
> mean(vec)
[1] 16.80036
> vec.ruid<-c(vec,rnorm(1,300,100))
> mean(vec.ruid)
[1] 35.36422
```

Medidas de Tendencia Central (2)

- Podemos robustecer la media eliminando una fracción de los valores extremos usando la media truncada o trimmed mean.
- En R podemos darle un segundo parámetro a la función mean llamado trim que define la fracción de elementos extremos a descartar.
- Ejemplo: Descartamos el 10 % de los valores extremos en el ejemplo anterior:

```
> mean(vec,trim=0.1)
[1] 17.78799
> mean(vec.ruid,trim=0.1)
[1] 19.51609 # Mucho más robusto
```

Medidas de Tendencia Central (3)

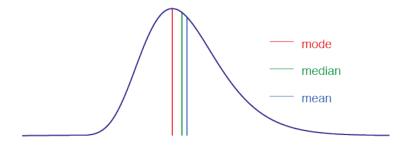
- La mediana representa de posición central de la variable que separa la mitad inferior y la mitad superior de las observaciones.
- Intuitivamente, consiste el valor donde para una mitad de las observaciones todos los valores son mayores que ésta, y para la otra mitad todos son menores.

$$\operatorname{median}(x) = \left\{ \begin{array}{cc} x_{r+1} & \operatorname{Si} m \text{ es impar con } m = 2r + 1 \\ \frac{1}{2}(x_r + x_{r+1}) & \operatorname{Si} m \text{ es par con } m = 2r \end{array} \right.$$

 Para el ejemplo anterior, vemos que la mediana es más robusta al ruido que la media:

```
> median(vec)
[1] 17.64805
> median(vec.ruid)
[1] 17.64839
```

Comparación entre la moda, la mediana y la media



Percentiles o Cuantiles

- El k-ésimo percentil de una variable numérica es un valor tal que el k % de las observaciones se encuentran debajo del percentil y el (100 – k) % se encuentran sobre este valor.
- En estadística se usan generalmente los cuantiles que son equivalentes a los percentiles expresados en fracciones en vez de porcentajes.
- En R se calculan con el comando quantile:

```
# Todos los percentiles
quantile(Sepal.Length,seq(0,1,0.01))
```

- Además es muy común hablar de los cuartiles que son tres percentiles específicos:
 - El primer cuartil Q_1 (lower quartile) es el percentil con k = 25.
 - El segundo cuartil Q_2 es con k = 50 que equivale a la mediana.
 - El tercer cuartil Q_3 (upper quartile) es con k = 75.

```
# El mínimo, los tres cuartiles y el máximo
> quantile(Sepal.Length,seq(0,1,0.25))
   0% 25% 50% 75% 100%
4.3 5.1 5.8 6.4 7.9
```

Resumiendo un Data Frame

- En R podemos resumir varias estadísticas de resumen de una variable o de un data.frame usando el comando summary.
- Para las variables numéricas nos entrega el mínimo, los cuartiles, la media y el máximo.
- Para las variables categóricas nos entrega la tabla de frecuencias.

```
> summary(iris)
Sepal.Length
              Sepal.Width Petal.Length
                                          Petal Width
Min. :4.300 Min. :2.000
                             Min.
                                   :1.000
                                           Min. :0.100
1st Qu.:5.100 1st Qu.:2.800
                             1st Ou.:1.600
                                           1st Ou.:0.300
Median :5.800
              Median :3.000
                             Median :4.350
                                           Median :1.300
Mean :5.843 Mean :3.057
                            Mean :3.758
                                          Mean :1.199
3rd Ou.:6.400 3rd Qu.:3.300
                            3rd Qu.:5.100
                                           3rd Ou.:1.800
Max. :7.900
              Max. :4.400
                             Max. :6.900
                                           Max. :2.500
```

Species setosa :50 versicolor:50 virginica :50

Ejercicio

- Usando el comando tapply analice la media, la mediana y los cuartiles para las tres especies de Iris para las cuatro variables.
- ¿Nota alguna diferencia en las distintas especies?

```
tapply(iris$Petal.Length,iris$Species,summary)
tapply(iris$Petal.Width,iris$Species,summary)
tapply(iris$Sepal.Length,iris$Species,summary)
tapply(iris$Sepal.Width,iris$Species,summary)
```

Medidas de Dispersión

- Estas medidas nos dicen que tan distintas o similares tienden a ser las observaciones respecto a un valor particular. Generalmente este valor se refiere a alguna medida de tendencia central.
- El rango es la diferencia entre el valor máximo y el mínimo:

```
> max(Sepal.Length)-min(Sepal.Length)
[1] 3.6
```

 La desviación estándar es la raíz cuadrada de la varianza que mide las diferencias cuadráticas promedio de las observaciones con la media.

$$var(x) = \frac{1}{m-1} \sum_{i=1}^{m} (x_i - \overline{x})^2$$

$$sd(x) = \sqrt{var(x)}$$

```
> var(Sepal.Length)
[1] 0.6856935
> sd(Sepal.Length)
[1] 0.8280661
```

Medidas de Dispersión (2)

- Al igual que la media, la desviación estándar es sensible a outliers.
- Las medidas más robustas se basan generalmente en la media.
- Sea m(x) una medida de tendencia central de x (usualmente la mediana), se define la desviación media absoluta (AAD) como:

$$AAD(x) = \frac{1}{m} \sum_{i=1}^{m} |x_i - m(x)|$$

 Programe la función add en R, como una función que recibe un vector x y una función de media central fun. El valor absoluto se calcula con el comando abs:

```
aad<-function(x, fun=median) {
  mean(abs(x-fun(x)))
}
> aad(Sepal.Length)
[1] 0.6846667
> aad(Sepal.Length, mean)
[1] 0.6875556
```

Medidas de Dispersión (3)

• Sea *b* una constante de escala se define la **desviación media absoluta** como:

$$\mathsf{MAD}(x) = b \times \mathsf{median}(|x_i - \mathsf{m}(x)|)$$

 En R se calcula con el comando mad con los parámetros center como un valor de la centralidad de la variable y constant como la constante b. Por defecto se usa la mediana y el valor 1,482.

```
> mad(Sepal.Length)
[1] 0.7
```

• Finalmente, se define el rango inter-cuartil (IQR) como la diferencia entre el tercer y el primer cuartil $(Q_3 - Q_1)$.

```
IQR(Sepal.Length)
[1] 1.3
```

Estadísticas de Resumen Multivariadas

- Para comparar como varía una variable respecto a otra, usamos medidas multivariadas.
- La covarianza cov(x, y) mide el grado de variación lineal conjunta de un par de variables x, y:

$$cov(x,y) = \frac{1}{m-1} \sum_{i=1}^{n} (x - \overline{x})(y - \overline{y})$$

- Donde cov(x, x) = var(x)
- En R se calcula con el comando cov:

```
> cov(Sepal.Length, Sepal.Width)
[1] -0.042434
```

 Si le damos una matriz o un data.frame de variables numéricas, calcula una matriz de covarianzas:

Estadísticas de Resumen Multivariadas (2)

- Si dos variables son independientes entre sí, su covarianza es cero.
- Para tener una medida de relación que no dependa de la escala de cada variable, usamos la correlación lineal.
- Se define a la correlación lineal o coefiente de correlación de Pearson r(x, y) como:

$$r(x,y) = \frac{cov(x,y)}{sd(x)sd(y)}$$

- La correlación lineal varía entre -1 a 1. Un valor cercano a 1 indica que mientras una variable crece la otra también lo hace en una proporción lineal. Un valor cercano a -1 indica una relación inversa (una crece la otra decrece). Si la correlación es cercana a cero tenemos independencia lineal. Ojo que eso no implica que no pueda haber una relación no-lineal entre las variables.
- En R se calcula con el comando cor.

Tablas de Contingencia

- Para analizar la relación entre variables de naturaleza categórica usamos tablas de contingencia.
- La tabla se llena con las frecuencias marginales de todos los pares de valores entre dos variables categóricas.
- En R se crean usando el comando table que usábamos para frecuencias, pero entregándole dos vectores:

Visualización de Datos

- La visualización de datos es la transformación de un dataset a un formato visual que permita a las personas identificar las características y las relaciones entre los elementos del dataset.
- La visualización permite que las personas reconozcan patrones o tendencias en base a su criterio o expertiz en el dominio particular.



Representación

- Se entiende por representación como el mapeo que se hace a partir de los datos hacia un formato visual.
- Se traducen los datos, sus atributos y relaciones a elementos gráficos como puntos, líneas, formas y colores.
- Los objetos son usualmente representados como puntos.
- Los valores de atributos se representan como la posición de los puntos o las características de los puntos, ej: color, tamaño y forma.
- Cuando se usa la posición para representar los valores es simple detectar si es que se forman grupos de obejtos o la presencia de objetos atípicos.

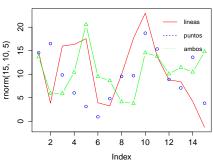
Graficando en R

- En R la función de visualización más frecuente en plot.
- Es una función genérica cuyo resultado depende de la naturaleza de las variables usadas.
- A todos los gráficos les podemos agregar parámetros adicionales como: main para el título, xlab e ylab para el nombre del eje x y del el eje y.
- Otras propiedades son col para definir el color, type para definir el tipo de gráfico: (p) para puntos o (l) para líneas.
- Además podemos agregarle nuevas capas a un gráfico con el comando lines.
- Para grabar una imagen en un archivo podemos usar el botón export de Bstudio
- Para hacerlo de la línea de comandos en R:

```
png("imagen.png")
plot(1:10)
dev.off()
```

Ejemplo

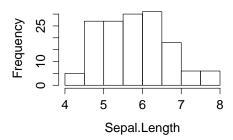
Mi gráfico



Histogramas

- Muestran la distribución de los valores de una variable.
- Los valores de los elementos se dividen en contenedores (bins) y se crean gráficos de barra por cada contenedor.
- La altura de cada barra indica el número de elementos o frecuencia del contenedor.
- En R se crean con el comando hist.
 - > hist (Sepal.Length)

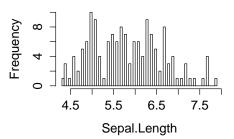
Histogram of Sepal.Length



Histogramas (2)

- La forma del histograma depende de el número de contenedores.
- En R se puede definir esa cantidad con el parámetro nolass.
 - > hist (Sepal.Length, nclass=100)

Histogram of Sepal.Length

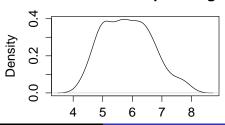


Densidad

- Otra forma de visualizar como se distribuyen los datos es estimando una densidad.
- Se calculan usando técnicas estadísticas no paramétricas llamadas estimación de densidad de kernel.
- La densidad es una versión suavizada del histograma y nos permite determinar más claramente si los datos observados se comportan como una densidad conocida ej: normal.
- En R se crean con el comando density, para luego visualizarlas con el comando plot.

plot(density(iris\$Sepal.Length), main="Densidad de Sepal.Length")

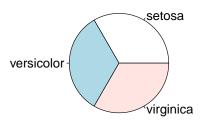
Densidad de Sepal.Length



Gráficos de Torta o Pie Charts

- Los gráficos de torta, gráficos circulares o pie charts representan la frecuencia de los elementos en un círculo.
- Cada elemento tiene una participación proporcional a su frecuencia relativa.
- Se usan generalmente para variables categóricas:

```
pie(table(iris$Species))
```



Boxplots

- Los Boxplots o diagramas de caja se construyen a partir de los percentiles.
- Se construye una rectángulo usando entre el primer y el tercer cuartil (Q1 y Q3).
- La altura del rectángulo es el rango intercuartil RIC $(Q_3 Q_1)$.
- La mediana es una línea que divide el rectángulo.
- Cada extremo del rectángulo se extiende con una recta o brazos de largo Q1 – 1,5*RIC para la recta inferior y Q₃ + 1,5*RIC para la recta superior.
- Los valores más extremos que el largo de los brazos son considerados atípicos.
- El boxplot nos entrega información sobre la simetría de la distribución de los datos.
- Si la mediana no está en el centro del rectángulo, la distribución no es simétrica.
- Son útiles para ver la presencia de valores atípicos u outliers.

Boxplots (2)

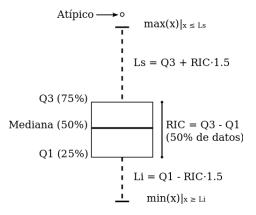
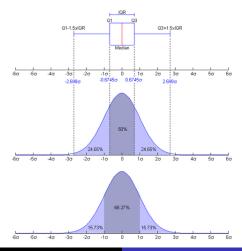


Figura: Fuente:

http://commons.wikimedia.org/wiki/File:Boxplot.svg

Boxplots (3)

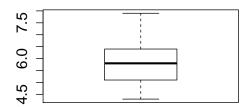
 El largo de los brazos así como el criterio para identificar valores atípicos se basa en el comportamiento de una normal.



Boxplots (4)

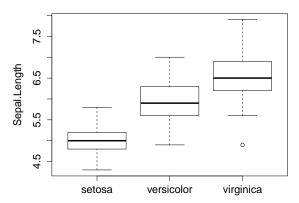
- En R los boxplots se grafican con el comando boxplot:
 - > boxplot(Sepal.Length, main="Boxplot Sepal.Length")

Boxplot Sepal.Length



Boxplots (4)

- Si tenemos una variable factor podemos crear un boxplot para cada categoría de la siguiente manera:
 - > boxplot (Sepal.Length~Species, ylab="Sepal.Length")

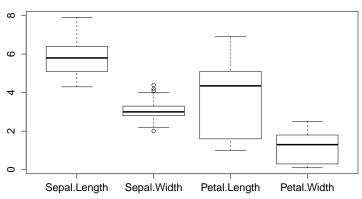


Boxplots (5)

También podemos podemos comparar varios boxplots en un mismo gráfico:

```
> boxplot(x=iris[,1:4],main="Boxplots Iris")
```

Boxplots Iris

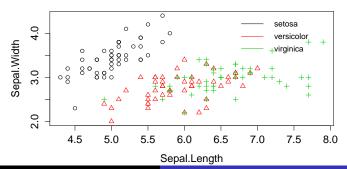


Diagramas de Dispersión

- Los diagramas de dispersión o scatter plots usan coordenadas cartesianas para mostrar los valores de dos variables del mismo largo.
- Los valores de los atributos determinan la posición de los elementos.
- Otros atributos pueden usarse para definir el tamaño, la forma o el color de los objetos.
- En R podemos graficar un scatterplot de dos variables numéricas usando el comando plot (x, y), que sería y vs x.
- También se pueden definir fórmulas f(x) = y usando la notación y^x .
- De esta manera el comando plot (y~x) es equivalente a plot (x, y).
- Si tenemos un data.frame o matriz numérica podemos ver los scatterplots de todos los pares usando el comando pairs (x).

Diagramas de Dispersión (2)

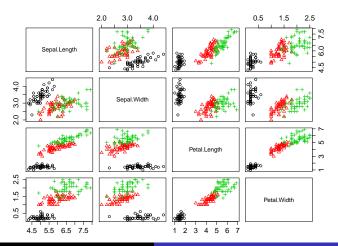
Ejemplos:



Diagramas de Dispersión (3)

Todos los pares de las 4 variables de irsi usando un color y un carácter distinto para cada especie:

pairs(iris[,1:4],pch=as.numeric(iris\$Species),col=iris\$Species)



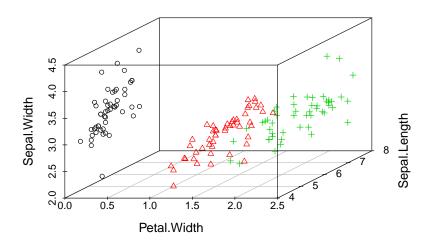
Diagramas de Dispersión (4)

- También se pueden crear scatterplots en tres dimensiones.
- Se debe instalar la librería scatterplot3d usando el siguiente comando:

```
install.packages("scatterplot3d", dependencies=T)
```

- Luego cargan la librería escribiendo library (scatterplot3d).
- Un scatterplot 3d para el ancho del pétalo, el largo del sépalo y el ancho del sépalo:

Diagramas de Dispersión (5)



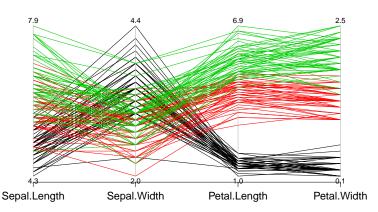
Gráficos de Coordenadas Paralelas

- Los gráficos de coordenadas paralelas son otra forma de visualizar datos multi-dimensionales.
- En vez de usar ejes perpendiculares (x-y-z) usamos varios ejes paralelos entre sí.
- Cada atributo es representado por uno de los ejes paralelo con sus respectivos valores.
- Los valores de los distintos atributos son escalados para que cada eje tenga la misma altura.
- Cada observación representa una línea que une los distintos ejes de acuerdo a sus valores.
- De esta manera, objetos similares entre sí tienden a agruparse en líneas con trayectoria similar.
- En muchas ocasiones es necesario realizar un re-ordenamiento de los ejes para poder visualizar un patrón.

Gráficos de Coordenadas Paralelas (2)

- En R podemos crear gráficos de coordenadas paralelas con el comando parcoord de la librería MASS.
- Ejemplo:

```
library(MASS)
parcoord(iris[1:4], col=iris$Species,var.label=T)
```



Otras técnicas de Visualización

Gráficos de Estrellas

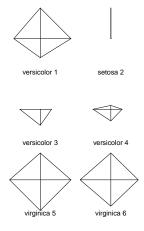
- También conocidos como gráficos radiales.
- Cada estrella representa una observación, formando un polígono a partir de cada variables con dirección a las agujas del reloj hasta formar un polígono.
- El tamaño de cada línea respecto al centro de la estrella corresponde al valor re-escalado de la variable.
- Sirve para comparar objetos o detectar valores atípicos.

Caras de Chernoff

- Enfoque creado por Herman Chernoff basado en la capacidad humana para distinguir rostros.
- Cada atributo corresponde a alguna característica de la cara (boca, ojos, nariz, etc..)
- El valor de los atributos determina la apariencia de la característica facial.
- Cada observación es una cara.

Ejemplo Star Plot

iris_sample1<-iris[sample(1:dim(iris)[1],size=6,replace=F),]
rownames(iris_sample1)<-paste(as.character(iris_sample1\$Species),1:6)
stars(iris_sample1[1:4])</pre>



Ejemplo Chernoff Face

```
library("aplpack")
iris_sample<-iris[sample(1:dim(iris)[1],size=16,replace=F),]
faces(iris_sample[1:4],face.type=1,labels=iris_sample$Species)</pre>
```



Bilbiografía I



Venables, William N., David M. Smith, and R Development Core Team. *An introduction to R.*, 2002.



Tan, P. N., Steinbach, M., & Kumar, V. Introduction to Data Mining, 2005.



http://cran.r-project.org/doc/contrib/grafi3.pdf